

Aplicatie ML pentru prezicerea nivelului de burnout

Marco Mihalca

May 17, 2026

1 Introduction

Aceasta aplicatie este una care incearca sa prezica un burnout, inainte ca acesta sa se intample, bazat pe date din trecut, cu multipli parametri care pot sa influenteze starea de bine a cuiva, facand alegeri educate. In asa fel, masuri de terapie, respectiv timp liber pot fi oferite inainte ca individul sa ajunga la extenuare completa.

1.1 Contextul Proiectului

In noul peisaj profesional, totul a inaintat rapid, acest mediu modern fiind caracterizat de catre o digitalizare accelerate si de fenomenul de a fi mereu conectat cu locul de munca, stresul cronic a devenit o provocare globala, in orice domeniu de angajare. Organizatia Mondiala a Sanatatii a recunoscut oficial extenuarea completa, numita burnout, a fi un sindrom rezultat din stresul cronic care a fost gestionat necorespunzator.

Aceasta epuizare a angajatilor nu afecteaza doar indivizi specifici atat la nivel mental cat si fizic, ci acesta are repercusiuni directe asupra organizatiilor prin scaderea productivitatii, cresterea erorilor si o rata ridicata de fluctuatie a personalului, prin angajati care demisioneaza.

1.2 Obiectivul Proiectului

Acest proiect are ca scop principal dezvoltarea unei solutii bazate pe "Machine Learning", capabila sa prezica nivelul de burnout al unui angajat, pe baza unor parametri de lucru si indicatori psihologici.

- **Analiza corelatiilor:** Identificarea factorilor care contribuie cel mai mult la epuizare.
- **Modelare predictiva:** Antrenarea unui model care sa ofere o estimare numerica precisa a riscului de burnout.

- **Automatizarea evaluarii:** Crearea unui instrument care poate procesa seturi mari de date, pentru a evidentia cazurile critice fara interventie umana constanta.

1.3 Impactul solutiei

Prin implementarea unui astfel de model AI, intr-o organizatie, aduce beneficii semnificative pe mai multe planuri, atat ca eficienta cat si ca profitabilitate:

- **Preventia proactiva:** Permite departamentelor de Resurse Umane sa intervina inainte ca un angajat sa ajunga la epuizare totala, oferind zile libere sau suport psihologic.
- **Optimizarea resurselor:** Managerii pot vedea daca anumite echipe sunt supraincarcate si pot redistribui sarcinile pentru a echilibra volumul de munca.
- **Cultura organizationala sanatoasa:** Demonstreaza angajamentul companiei fata de sanatatea mentala, ceea ce creste atat loialitatea cat si satisfactia angajatilor.
- **Reducerea costurilor:** Prevenirea burnout-ului scade costurile legate de recrutarea si instruirea de noi angajati, necesari in inlocuirea celor care pleaca din motive de sanatate, iar greselile acestora vor scadea, productivitatea crescand, fiind mult mai profitabili pentru companie.

2 EDA si curatarea datelor

Pentru aceasta aplicatie, am analizat doua seturi de date cu potential mare pentru a fi potrivite acestui proiect, insa mai jos am determinat diferentele dintre aceste doua seturi de date si care ofera cele mai relevante informatii pentru predictia burnout-ului.

2.1 Compararea seturilor de date

In prima faza a proiectului, am realizat o analiza comparative intre cele doua surse de date potentiale, pentru a putea identifica setul care ofera cea mai mare valoare, insa asigura si performanta modelului de Machine Learning, deoarece calitatea predictiilor depinde direct de diversitatea si integritatea datelor de intrare.

Caracteristică	Dataset 1 (Mental Health Survey)	Dataset 2 (Post-Pandemic Impact)
Nr. Observații	3.000 de rânduri	3.157 de rânduri
Nr. Variabile	25 coloane (Complexitate ridicată)	14 coloane (Simplist)
Integritatea Datelor	0 Valori lipsă (Set de date curat)	1.079 Valori lipsă (Necesită imputare)
Variabile Cheie	SleepHours, CommuteTime, ManagerSupport, BurnoutRisk	Mental_Health_Status, Social_Isolation_Score
Obiectiv ML	Regresie și Clasificare (0/1)	Predominant Regresie

Table 1: Comparatie intre seturile de date analizate

2.2 Justificarea alegerii

In urma compararii detaliate prezentate in tabelul de mai sus, am ales sa utilizez primul set de date (`mental_health_workplace_survey.csv`), din urmatoarele motive:

- **Granularitatea datelor:** Cele 25 de variabile permit o analiza multi-dimensională, aceasta incluzand factori externi locului de munca, precum orele de somn si timpul petrecut in trafic, care sunt extrem de importanti pentru a lua o decizie calitativa.
- **Capacitatea de clasificare:** Existenta coloanei BurnoutRisk, intr-un format binar, transforma proiectul intr-un instrument de diagnosticare preventiva, capabil sa categorizeze clar angajatii aflati in situatii critice.
- **Eficienta procesarii:** Absenta valorilor de tip NaN (Not a Number) elimina riscul de a introduce erori sistematice prin tehnici de completare artificiala a datelor, asigurand un antrenament al modelului precis, robust si a unor decizii calitative.

2.3 Procesul de curatare

Chiar daca setul ales este de inalta calitate, am aplicat urmatoarele etape de preprocesare pentru a-l pregati pentru algoritmi:

1. **Eliminarea identificatorilor inutili:** Am eliminat coloana "EmployeeID", deoarece din punct de vedere statistic, ID-urile sunt unice si nu au putere predictiva, iar pastrarea acestora duce la "overfitting", modelul invatand ID-uri, nu comportamente.
2. **Validarea lipsurilor:** Am confirmat, prin cod, ca nu exista valori de tip NaN (Not a Number) care ar putea bloca executia algoritmilor de Machine Learning.
3. **Analiza corelatiei:** Avand 25 de coloane, am selectat variabilele cu impactul cel mai mare asupra BurnoutLevel. (Ex: StressLevel si WorkHoursPerWeek)

3 Ingineria caracteristicilor si analiza importantei

In aceasta etapa, am transformat setul de date brut intr-un alt format, unul mult mai optim pentru antrenarea modelelor de Machine Learning si am analizat importanta/relevanta fiecarei variabile.

3.1 Transformarea datelor

Datorita faptului ca algoritmi de invatare automata lucreaza cu date numerice, am aplicat urmatoarele tehnici de transformare a variabilelor din setul de date ales:

- **Mapare binara:** Variabilele cu raspunsuri de tip "Yes/No" (ex: HasMentalHealthSupport, HasTherapyAccess) au fost transformate in valori de "1" si "0".
- **One-Hot encoding:** Pentru variabilele cu mai multe categorii, cum ar fi RemoteWork (Hybrid, Yes, No) si Gender, am utilizat functia get dummies, pentru a putea crea coloane specifice fiecarei categorii, astfel incat algoritmul sa nu impuna o ierarhie artificiala intre acestea.

3.2 Crearea de noi caracteristici (Feature Engineering)

Pentru a putea capta mai bine starea de bine a angajatilor si a identifica factorii care conduc la epuizare, am extras urmatoarele variabile noi din setul de date existent:

- **StressSupportRatio:** Reprezinta raportul dintre nivelul de stres si ajutorul primit de la manager. Acest indicator evidentiaza situatiile in care presiunea este mare, dar sustinerea oferita de catre organizatie nu este suficienta.
- **RecoveryIndex:** Un indice pentru recuperare, calculat prin insumarea orelor de somn cu orele de activitate fizica saptamanala.
- **WorkLifeBalanceIndex:** Ajusteaza scorul de echilibru munca-viata in functie de numarul de ore lucrate pe saptamana.
- **SalaryRank:** Transformarea variabilei categorice privind salariul intr-o forma numerica (de la 1 la 5), astfel facilitand interpretarea corelatiei dintre venit si burnout.
- **CommuteStressFactor:** Un factor de stres calculat prin inmultirea timpului de naveta zilnica cu nivelul de nesatisfactie la locul de munca.
- **TenureRatio:** Reprezinta raportul dintre anii petrecuti in companie si varsta individului, oferind o perspectiva asupra stabilitatii profesionale.

- **MentalHealthResilience:** Un scor de rezilienta care combina accesul la terapie si ajutorul pentru sanatate mentala, cu obiceiurile de recuperare fizica.
- **WorkLifeExtremity:** Masoara cat de mult deviaza stilul de viata al angajatului fata de valorile considerate echilibrate (40 ore de munca, 8 ore de somn, 5 ore de sport).
- **SatisfactionStressTension:** Calculeaza tensiunea psihologica rezultata din nivelul de stres si lipsa satisfactiei profesionale.
- **BurnoutRiskMultiplier:** Un multiplicator de risc ce amplifica interactiunea dintre orele lucrate si stres, cu suportul managerial si satisfactia jobului.
- **CareerVsSatisfaction:** Diferenta dintre scorul de crestere in cariera si satisfactia actuala, indicand posibile frustrari profesionale.
- **WellnessIndex:** Un indicator (0-100) care integreaza somnul, activitatea fizica, satisfactia, echilibrul si ajutorul pentru sanatatea mentala.
- **SleepDeficit:** Calculeaza lipsa orelor de somn fata de pragul optim de 8 ore pe noapte.
- **SatisfactionStressGap:** Raportul dintre satisfactie si stres, oferind o masura a eficientei emotionale a angajatului.
- **WorkRecoveryRatio:** Reprezinta raportul dintre orele de munca saptamanale si capacitatea totala de recuperare (somn si sport), fiind un predictor direct al extenuarii.

3.3 Analiza importantei caracteristicilor

Pentru a putea determina care factori au cel mai mare impact asupra riscului de burnout, am utilizat un model de tip Random Forest Classifier. Avantajul acestui model este in capacitatea de a genera un scor de importanta pentru fiecare variabila.

Conform analizei efectuate, pe setul de date hybrid:

- Factorii principali au fost identificati si vizualizati printr-un grafic, facilitand prioritizarea corespunzatoare a variabilelor pentru modelul final de predictie.
- Aceasta etapa ne-a dat voie sa eliminam variabilele cu putere predictiva scazuta, reducand complexitatea inutila a modelului si riscul de overfitting.

4 Optimizarea și Selecția Caracteristicilor

Obiectivul principal al acestei etape a fost combaterea **multicoliniarității** și a **redundanței**, fenomene care pot induce erori în estimările algoritmului de Machine Learning.

În urma procesului de curățare și optimizare documentat în notebook-ul jupyter, am eliminat 10 variabile din motivele explicate mai jos:

1. PersonalTimeScore vs. RecoveryIndex

- **Formulă:** Ambele utilizau $SleepHours + PhysicalActivityHrs$
- **Motiv:** Sunt **identice**. Păstrarea ambelor ar fi creat o multicoliniaritate perfectă (1.0), forțând modelul să învețe aceeași informație de două ori fără beneficii.
- **Verdict:** S-a păstrat doar RecoveryIndex.

2. WorkSleepRatio vs. WorkRecoveryRatio

- **Formulă:** $WorkHours / (SleepHours \times 7)$ vs. $WorkHours / (SleepHours + PhysicalActivityHrs)$.
- **Motiv:** Prima formulă folosea un multiplicator artificial și ignora complet activitatea fizică ca metodă de recuperare. **WorkRecoveryRatio** oferă o imagine mult mai concisă și realistă.
- **Verdict:** S-a eliminat WorkSleepRatio.

3. StressManagementCapacity vs. SatisfactionStressGap + ManagerSupportEfficiency

- **Formulă:** $(Support + Balance + Satisfaction) / (Stress + 1)$.
- **Motiv:** Reprezenta o medie complexă a factorilor pozitivi, pierzând granularitatea datelor. Modelul este mai precis dacă procesează separat relația satisfacție-stres și eficiența suportului managerial.
- **Verdict:** Eliminat în favoarea caracteristicilor specifice.

4. BurnoutTriggersRatio vs. Features Individuale

- **Formulă:** $FactoriNegativi / (FactoriPozitivi + 1)$.
- **Motiv:** Combinația liniară a factorilor de stres și satisfacție este redundantă pentru modele precum **Random Forest**, care pot deduce automat aceste interacțiuni.
- **Verdict:** Eliminat pentru a reduce complexitatea.

5. CommuteFatigueFactor vs. CommuteStressFactor

- **Formulă:** $CommuteTime \times Stress / 100$.

- **Motiv:** Variabila era prea simplistă. **CommuteStressFactor** ($CommuteTime \times (10 - JobSatisfaction)$) este mult mai informativ, deoarece include satisfacția ca factor de compensare.
- **Verdict:** S-a păstrat doar CommuteStressFactor.

6. WorkOverloadIndex vs. WorkRecoveryRatio

- **Formulă:** $WorkHours / (SleepHours + PhysicalActivityHrs)$.
- **Motiv:** S-a identificat o redundanță totală, formulele fiind **identice**. Reprezenta doar o denumire diferită pentru același concept matematic, ceea ce poate induce confuzie în deciziile luate de către algoritm.
- **Verdict:** S-a păstrat doar WorkRecoveryRatio.

7. RecoveryQualityScore vs. RecoveryIndex

- **Formulă:** $(SleepHours \times PhysicalActivityHrs) / (WorkHours + 1)$.
- **Motiv:** Cele două variabile aveau o corelație de peste **0.90**. Versiunea multiplicativă adăuga zgomot statistic fără a îmbunătăți predicția față de suma simplă.
- **Verdict:** S-a păstrat RecoveryIndex.

8. ManagerSupportEfficiency vs. Componente Individuale

- **Formulă:** $(Support \times Satisfaction) / (Stress + 1)$.
- **Motiv:** Această transformare genera multicolaritate cu variabilele de bază. Este preferabil ca modelul să determine singur ponderea suportului și a satisfacției.
- **Verdict:** S-a eliminat pentru a evita bias-ul.

9. HealthInvestment vs. RecoveryIndex

- **Formulă:** $SleepHours + PhysicalActivityHrs + (DaysOff/5)$.
- **Motiv:** Corelație extremă (> 0.95) cu RecoveryIndex. Componenta de zile libere aducea o modificare minoră care nu justifică păstrarea unei variabile aproape duplicate.
- **Verdict:** S-a păstrat RecoveryIndex pentru simplitate.

10. SupportDeficit vs. StressLevel

- **Motiv:** S-a observat o corelație de peste **0.80** între lipsa suportului și nivelul de stres raportat. Păstrarea ambelor ar fi "păcălit" modelul să supraestimeze importanța acestui canal de date.
- **Verdict:** S-a eliminat pentru a stabili modelul.

4.1 Concluzii privind Optimizarea Setului de Date

Procesul de rafinare a caracteristicilor a condus la o reducere de **40%** a complexității modelului, scăzând numărul de variabile *engineered* de la 25 la 15. Această "curățenie" statistică a avut un impact diferențiat asupra algoritmilor testați:

- **Impactul asupra modelelor liniare și simple:** Majoritatea modelelor (precum Regresia Logistică sau SVM) au înregistrat o **creștere majoră** în performanță. Eliminarea zgomotului și a multicolarității a permis acestor algoritmi să identifice mult mai clar semnalele predictive, rezultând într-o creștere directă a acurateței.
- **Comportamentul Random Forest:** Spre deosebire de restul modelelor, algoritmul **Random Forest** nu a prezentat o creștere a acurateței globale. Acest lucru este justificat de natura algoritmului, care este oarecum "imun" la variabilele redundante prin tehnica de selecție aleatorie a caracteristicilor în nodurile arborilor de decizie.
- **Rafinarea metricilor de calitate (F1-Score și Recall):** Deși acuratețea Random Forest a stagnat, s-a observat o îmbunătățire la nivelul scorului **F1** și al parametrului **Recall**. Dintr-o perspectivă statistică, acesta este cel mai important rezultat: modelul a devenit mai capabil să identifice corect angajații aflați la risc (scor Recall ridicat), reducând probabilitatea ca un caz de burnout să treacă neobservat.

Verdict final: Reducerea dimensiunii setului de date a condus la un model mai "ușor", mai rapid și mai stabil. Chiar dacă Random Forest și-a menținut acuratețea, capacitatea sa de a diagnostica corect riscul (prin scorul F1 și Recall) a fost optimizată, validând astfel efortul de selecție a caracteristicilor.

5 Optimizarea Hiperparametrilor și Compararea Modelelor

Pentru a maximiza performanța algoritmilor și a ne asigura că modelele nu memorează pur și simplu datele, am implementat o strategie riguroasă de validare și ajustare folosind *GridSearchCV*. Această metodă a explorat sistematic multiple combinații de hiperparametri pentru a identifica configurația optimă pentru fiecare algoritm în parte.

5.1 Evoluția Modelelor prin GridSearchCV

În urma etapei de *fine-tuning*, s-a observat o dinamică interesantă în performanța modelelor evaluate, subliniind importanța metodelor de optimizare în procesul de Machine Learning:

- **Aducerea la nivel a modelelor secundare:** După aplicarea *GridSearchCV*, restul modelelor evaluate (precum Regresia Logistică sau SVM) au beneficiat de o îmbunătățire majoră. Acestea au ajuns la un nivel de acuratețe aproape egal cu performanța pe care algoritmul Random Forest a avut-o încă de la început (în stadiul său *baseline*).
- **Ajustarea fină a Random Forest:** Deși optimizarea hiperparametrilor nu a adus o creștere vizibilă a *acurateței* globale pentru **Random Forest**, impactul a fost unul calitativ. Modelul ajustat a devenit mult mai capabil să recunoască și să clasifice corect cazurile pozitive de burnout. Astfel, prin limitarea adâncimii arborilor și ajustarea criteriilor de separare, Random Forest și-a îmbunătățit capacitatea de generalizare, scăzând rata de fals-negative.

5.2 Performanța K-Nearest Neighbors (KNN) vs. Random Forest

O observație critică a acestei etape de evaluare a apărut la analiza algoritmului **K-Nearest Neighbors (KNN)**. Rezultatele au arătat o deviație interesantă între metricile de volum (Acuratețe) și metricile de diagnostic (Recall și F1-Score):

- **KNN** a raportat o acuratețe marginal mai mică comparativ cu Random Forest. Cu toate acestea, în urma optimizărilor *GridSearchCV*, KNN a obținut scoruri **semnificativ îmbunătățite pentru F1 și Recall**.
- În contextul domeniului de Resurse Umane și Sănătate Mentală, un scor **Recall** ridicat este mult mai valoros decât o acuratețe perfectă. Este preferabil ca modelul să genereze câteva alarme false (fals-pozitive) decât să rateze un angajat aflat într-un stadiu critic de burnout (fals-negativ).

Concluzie: Deși Random Forest rămâne un algoritm extrem de robust și precis, performanța remarcabilă a KNN în detectarea pozitivă a cazurilor de

risc îl transformă într-un instrument deosebit de util pentru obiectivul principal al aplicației: predicția proactivă și protejarea stării de bine a angajaților.

5.3 Abordarea Dezechilibrului claselor și Optimizări Avansate

În încercarea de a rafina capacitatea de detecție a minorității (angajații cu risc ridicat de burnout), am explorat tehnici de reeșantionare și optimizare stochastică. Rezultatele au oferit o perspectivă valoroasă asupra compromisului dintre acuratețea globală și puterea de diagnostic a modelului.

5.4 Impactul SMOTE (Synthetic Minority Over-sampling Technique)

Pentru a contracara dezechilibrul claselor (*class imbalance*), am aplicat algoritmul **SMOTE**. Deși teoretic această metodă ar fi trebuit să ajute modelele să învețe mai bine clasa minoritară, rezultatele experimentale au fost neașteptate:

- **Degradarea performanței generale:** Cu excepția algoritmului **CatBoost**, care a rămas relativ stabil, restul modelelor au suferit o **scădere majoră a acurateței**. Această intervenție a transformat modele anterior performante în predictorii care, în anumite cazuri, au raportat rezultate mai slabe decât un *random classifier*.
- **Explicație tehnică:** Această prăbușire sugerează că generarea de eșantioane sintetice a introdus prea mult zgomot în spațiul caracteristicilor sau a creat suprapuneri între clase, forțând modelele liniare și KNN să piardă granițele clare de decizie.

5.5 Optimizarea Bayesiană

Am testat, de asemenea, utilizarea **Optimizării Bayesiene** pentru căutarea hiperparametrilor, sperând că o abordare mai inteligentă decât *GridSearch* va compensa scăderile de performanță. Totuși, nici această metodă nu a adus îmbunătățiri semnificative față de rezultatele anterioare. În consecință, am luat decizia de a **renunța la acest tip de optimizare**, considerând că resursele computaționale nu justifică câștigul marginal nul.

5.6 KNN – Reziliența în Detecția Burnout-ului

În acest peisaj de performanțe fluctuante, algoritmul **KNN (K-Nearest Neighbors)** a demonstrat un comportament remarcabil:

- În ciuda unei acuratețe globale scăzute, **KNN s-a remarcat prin menținerea unui scor F1 și a unui Recall semnificativ de mari**.
- Chiar dacă rata de predicție corectă per total a scăzut din cauza dezechilibrului claselor, capacitatea KNN de a "găsi" cazurile reale de burnout a rămas ridicată. Acest lucru confirmă faptul că, pentru o aplicație de

sănătate mentală, proximitatea în spațiul caracteristicilor (specifică KNN) este un indicator mai fidel al stării angajatului decât modelele care încearcă să optimizeze doar acuratețea matematică brută.

Concluzie: Experimentul cu SMOTE a demonstrat că **CatBoost** este cel mai robust algoritm la modificările de eșantionare, în timp ce **KNN** rămâne cel mai bun instrument de "screening" (detectare a cazurilor pozitive), chiar și într-un mediu cu date zgomotoase.

6 Alegerea Modelului Final

În urma derulării tuturor experimentelor și a evaluării algoritmilor pe setul de date ales, a aplicării tehnicilor de eșantionare și ajustare a pragului de decizie, etapa finală este reprezentată de către selecția modelului predictiv care este cel mai potrivit, cel mai optim. Acest capitol detaliază argumentele care au stat la baza alegerii acestui algoritm, acesta fiind XGBoost, ca algoritm principal al aplicației de predicție a burnout-ului.

6.1 Justificarea Selecției Modelului XGBoost

Deși modelele testate anterior au oferit performanțe competitive, algoritmul XGBoost a fost selectat ca model final datorită capacității sale superioare de generalizare și a modului eficient în care gestionează relațiile non-liniare complexe dintre indicatorii de sănătate și restul variabilelor.

Din punct de vedere al acurateții, XGBoost evoluează *on par* (la același nivel) cu restul modelelor de top analizate (cum ar fi CatBoost sau Random Forest). Cu toate acestea, în urma unei analize amănunțite, segmentul de sănătate mentală și management al stresului, acuratețea matematică brută nu constituie o metrică suficientă. Superioritatea incontestabilă a modelului XGBoost a apărut în optimizarea simultană a două metrici fundamentale pentru seturile de date dezechilibrate: scorul F1 și indicatorul Recall.

6.2 Analiza Metricilor în Contextul Dezechilibrului Datelor

Setul de date utilizat (`mental_health_workplace_survey.csv`) prezintă o distribuție inegală a claselor, cazurile de burnout fiind numeric inferioare celor de non-burnout. Într-un astfel de scenariu, un model slab optimizat ar putea raporta o acuratețe ridicată prin simpla predicție majoritară a clasei negative, ignorând complet subiecții aflați în stare de risc.

XGBoost corectează această deficiență prin funcția sa de cost avansată și prin flexibilitatea în configurarea ponderilor claselor. Rezultatele experimentale au demonstrat că:

- **Recall-ul maximizat:** XGBoost a obținut cel mai ridicat scor de Recall dintre toate modelele testate. Aceasta înseamnă că modelul minimizează rata cazurilor fals negative, identificând cu succes cea mai mare parte a angajaților care se îndreaptă cu adevărat spre extenuare.
- **Scorul F1 optim:** Spre deosebire de alte abordări în care creșterea Recall-ului penalizează drastic Precizia (generând prea multe alerte false), XGBoost a obținut și cel mai bun scor F1. Acest lucru confirmă păstrarea unui echilibru statistic remarcabil, modelul fiind extrem de specific în delimitarea claselor fără a sacrifica robustețea generală.

6.3 Implicații Practice și Impactul Asupra Managementului Resurselor Umane

Dintr-o perspectivă operațională, alegerea XGBoost aduce avantaje directe în implementarea reală a aplicației:

1. **Prevenție timpurie eficientă:** Obținerea unui Recall ridicat asigură organizația că numărul persoanelor aflate în prag de burnout care trec nedetectate de sistem este minim. Acest lucru permite declanșarea măsurilor preventive (concedii medicale, consiliere psihologică, reducerea volumului de muncă) înainte ca starea de epuizare să devină ireversibilă.
2. **Alocarea optimă a resurselor:** Mulțumită unui scor F1 ridicat, departamentele de Resurse Umane nu vor fi copleșite de alerte fals pozitive. Intervențiile vor fi direcționate strict către cazurile unde riscul este validat statistic, optimizând astfel costurile și timpul alocat programelor de suport.

6.4 Concluzii privind Arhitectura Sistemului Predictiv

În concluzie, XGBoost nu reprezintă doar un algoritm performant din punct de vedere matematic, ci soluția ideală adaptată specificului proiectului. Acesta oferă stabilitatea structurală necesară pentru a funcționa ca motor de predicție în timp real, transformând datele brute colectate din mediul de lucru în decizii medicale și organizaționale fundamentate, capabile să protejeze capitalul uman al unei organizații.

7 Concluzii

Dezvoltarea acestei aplicații de predicție a burnout-ului a oferit o serie de perspective valoroase, atât din punct de vedere al ingineriei datelor și antrenării modelelor de Machine Learning, cât și din perspectiva aplicabilității practice a inteligenței artificiale în managementul resurselor umane.

7.1 Limitările Acurateței în Seturile de Date Dezechilibrate

Una dintre cele mai importante lecții practice a fost demontarea iluziei acurateței globale ca metrică supremă de evaluare. Într-un mediu în care cazurile de burnout reprezintă clasa minoritară, un model slab optimizat poate atinge o acuratețe ridicată prin simpla favorizare a clasei majoritare. Am învățat că în scenariile cu impact direct asupra sănătății umane, validarea modelelor trebuie să se axeze pe **Recall** (pentru minimizarea cazurilor fals negative) și pe **Scorul F1** (pentru o viziune de ansamblu echilibrată).

7.2 Impactul Preprocesării: SMOTE și Threshold Tuning

Experimentele au demonstrat că algoritmul în sine reprezintă doar o parte din soluție. Aplicarea tehnicilor de supraeșantionare (*SMOTE*) a claselor minoritare și ajustarea manuală a pragului de decizie (*Threshold Tuning*) au schimbat radical comportamentul modelelor. Scăderea aparentă a acurateței generale după aplicarea acestor tehnici s-a dovedit a fi, în mod contraintuitiv, un succes tehnic, deoarece a semnalat o sensibilitate mult mai mare a algoritmilor (precum KNN sau XGBoost) în detectarea cazurilor reale de epuizare.

7.3 Diferențele de Comportament între Algoritmi

Pe parcursul evaluărilor, s-a observat clar modul distinct în care diferiți algoritmi abordează spațiul caracteristicilor:

- **Modelele Ensemble (XGBoost, CatBoost, Random Forest):** Au demonstrat o capacitate superioară de a generaliza și de a capta relațiile non-liniare complexe dintre nivelul de stres, istoricul medical și factorii de la locul de muncă, dovedindu-se extrem de robuste la zgomotul din date.
- **Modelele bazate pe distanță (KNN):** Deși au suferit penalizări la nivel de acuratețe brută, au arătat o reziliență surprinzătoare în menținerea unui Recall ridicat.

7.4 Traducerea Metricilor Matematice în Decizii Organizaționale

Nu în ultimul rând, proiectul a evidențiat nevoia ca dezvoltatorul să înțeleagă domeniul de aplicabilitate al datelor. Selecția finală a modelului XGBoost nu s-a bazat doar pe un clasament abstract al algoritmilor, ci pe o nevoie de *business*: asigurarea că un număr cât mai mic de angajați aflați în pragul epuizării sunt

omiși de sistem. Astfel, Machine Learning-ul devine o unealtă de prevenție activă, capabilă să declanșeze măsuri de suport la momentul optim.